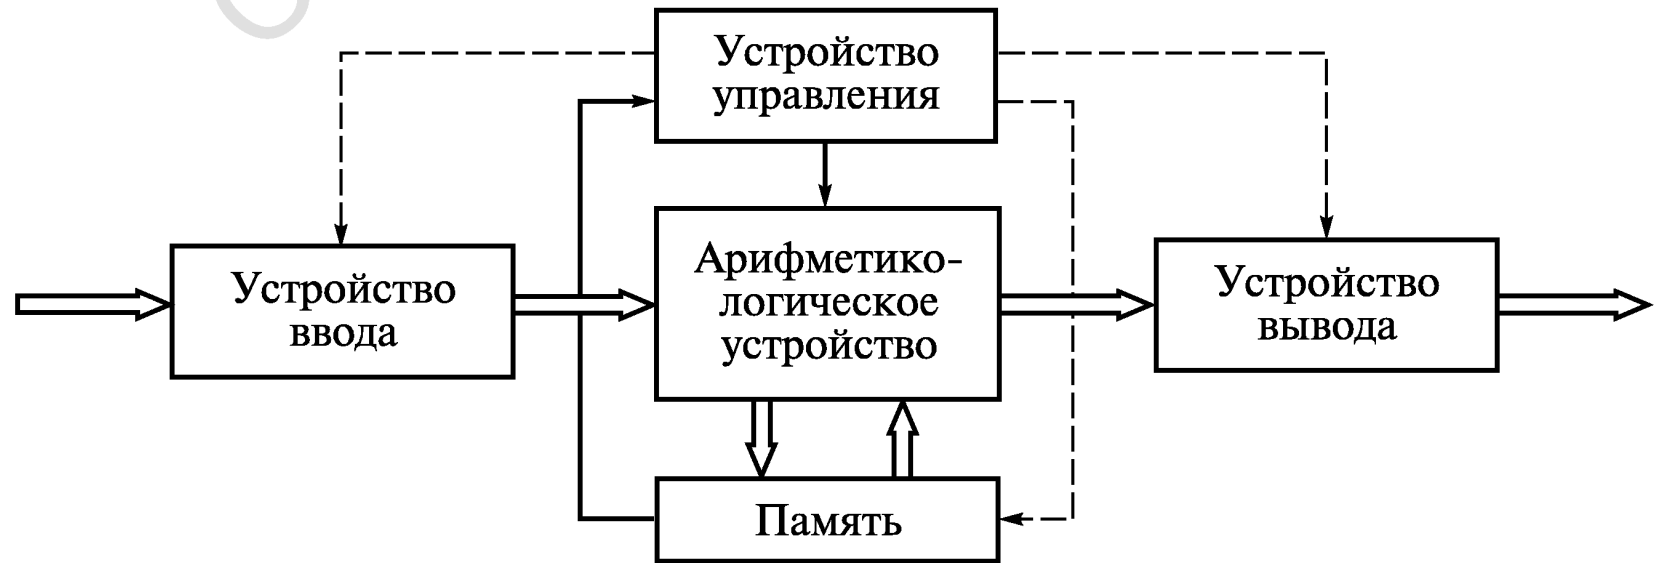


12. Введение в программирование на языке ассемблера. Часть 1

Разделы:

- Основы программирования на языке ассемблера с использованием GNU *Assembler*
- Система команд с примерами использования
- Подпрограммы и их вызов

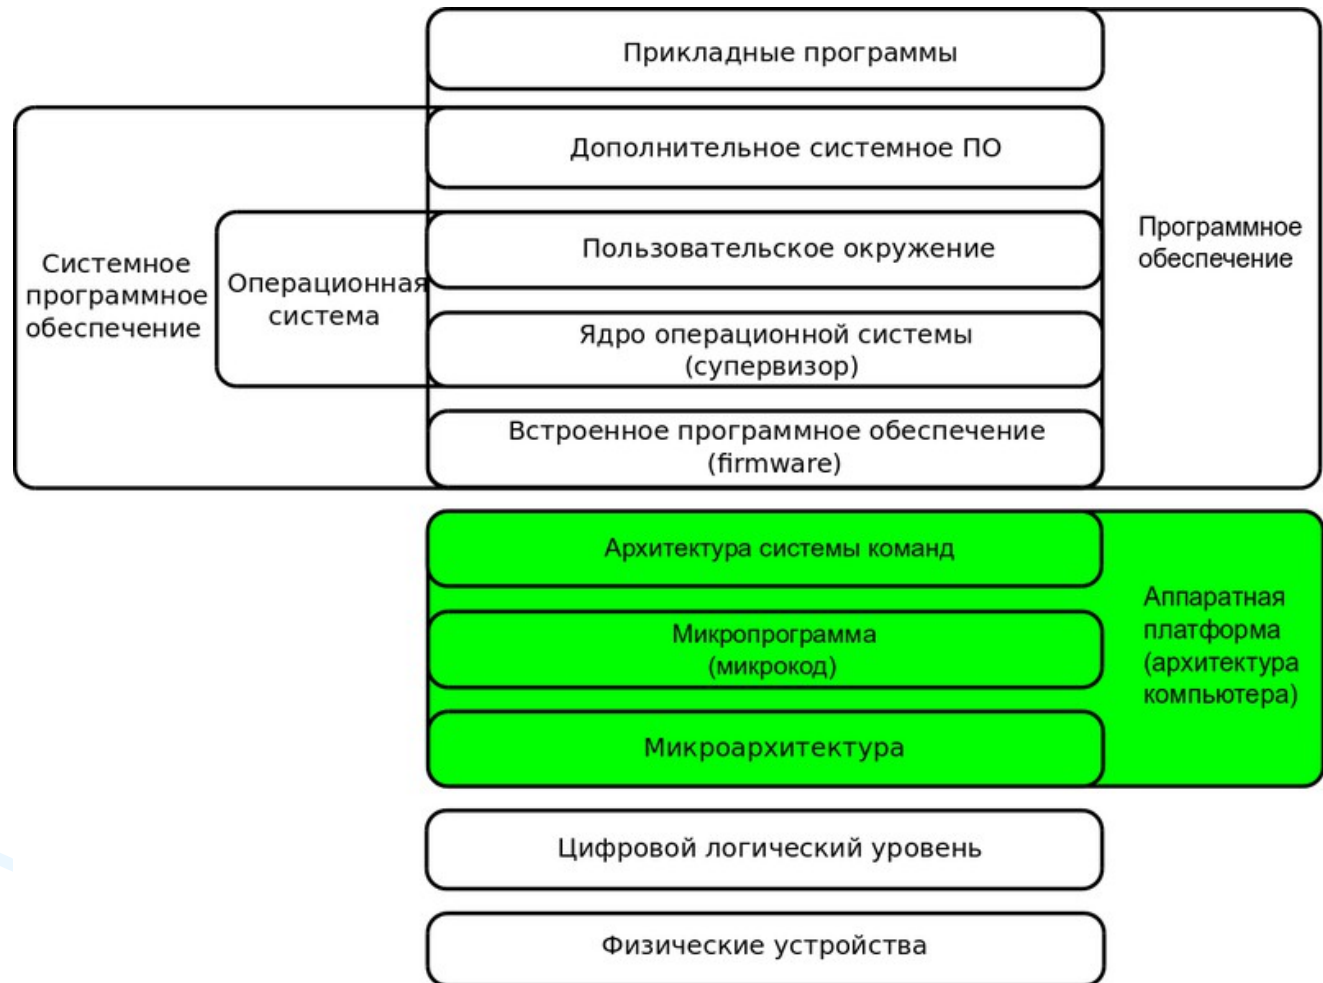
Архитектура вычислительных машин



⇒ линии связи для данных; → линии связи для команд; — — → линии связи для управления

- Источник — книга Мелехина В.Ф. и Павловского Е.Г. «Вычислительные машины, системы и сети» (доступен из корпоративной сети СФУ) - <http://lib3.sfu-kras.ru/ft/lib2/elib/u004/i-705826.djvu?>

Архитектура вычислительных машин



- Источник —

<https://ru.wikipedia.org/wiki/Файл:GeneralizedLayered>

Программирование на ассемблере для x86

- Зачем изучать Ассемблер и программировать на нем?
 - Большую часть задач решает “plain” C
 - Очень небольшая часть ядра Linux и весьма специфическая часть системных библиотек написана на Ассемблере
- Но:
 - программист, не понимающий, как работает процессор на уровне команд, «не ведает, что творит»
 - отсюда получают офисные приложения, не помещающиеся в отведенные 4 Гб
- Целевая архитектура 1 - x86, синтаксис Ассемблера – AT&T, вместо принятого в Windows – Intel-синтаксиса, рабочий инструмент – *gas*
- Целевая архитектура 2 - MIPS32, рабочий инструмент – текстовый редактор + симулятор SPIM



Программирование на ассемблере для x86

- Регистры общего назначения (Размер – 32 бита)
 - %eax: Accumulator register
 - %ebx: Base register
 - %ecx: Counter register
 - %edx: Data register
 - %esp: Stack pointer register
 - %ebp: Base pointer register
 - %esi: Source index register
 - %edi: Destination index register
 - регистры математического сопроцессора
 - регистры MMX, SSE, SSE2, SSE3 etc.

Программирование на ассемблере для x86

- К младшим 16 битам регистра `%eax` можно обратиться как `%ax`
- В свою очередь, `%ax` содержит две однобайтовых части, которые могут использоваться как самостоятельные регистры: старший `%ah` и младший `%al`


Аналогично можно обращаться к

`%ebx/%bx/%bh/%bl` `%ecx/%cx/%ch/%cl`

`%edx/%dx/%dh/%dl`

`%esi/%si`

`%edi/%di`





Программирование на ассемблере для x86

- Сегментные регистры:
 - `%cs`: Code segment
 - `%ds`: Data segment
 - `%ss`: Stack segment
 - `%es`: Extra segment
 - `%fs`: F segment
 - `%gs`: G segment
- ОС предоставляет специальные средства - системный вызов *modify_ldt()*
- Они позволяют описывать нестандартные сегменты и работать с ними
- Однако такая потребность возникает редко

Программирование на ассемблере для x86

- Флаги:

- cf: *carry flag*, флаг переноса:

- 1 — во время арифметической операции был произведён перенос из старшего бита результата;
 - 0 — переноса не было;

- zf: *zero flag*, флаг нуля:

- 1 — результат последней операции нулевой;
 - 0 — результат последней операции ненулевой;

- of: *overflow flag*, флаг переполнения:

- 1 — во время арифметической операции произошёл перенос в/из старшего (знакового) бита результата;
 - 0 — переноса не было;

- df: *direction flag*, флаг направления. Указывает направление просмотра в строковых операциях:

- 1 — направление «назад», от старших адресов к младшим;
 - 0 — направление «вперёд», от младших адресов к старшим.



Программирование на ассемблере для x86

- Указатель команды *eip* (*instruction pointer*)
- Размер — 32 бита
- Содержит указатель на следующую команду
- Напрямую недоступен, изменяется неявно командами условных и безусловных переходов, вызова и возврата из подпрограмм

Программирование на ассемблере для x86

```
/* Компилировать: $gcc hello.s -o hello */
.data                                     /* поместить следующее в сегмент данных */
hello_str:                               /* наша строка */
.string "Hello, goodbye and farewell!\n" /* длина строки */
.set hello_str_length, . - hello_str - 1
.text                                     /* поместить следующее в сегмент кода */
.globl main                             /* main - глобальный символ, видимый
                                         за пределами текущего файла */
.type main, @function                   /* main - функция (а не данные) */
main:
    movl    $4, %eax                    /* поместить номер системного вызова
                                         write = 4 в регистр %eax */
    movl    $1, %ebx                    /* первый параметр - в регистр %ebx;
                                         номер файлового дескриптора
                                         stdout - 1 */
    movl    $hello_str, %ecx            /* второй параметр - в регистр %ecx;
                                         указатель на строку */
    movl    $hello_str_length, %edx     /* третий параметр - в регистр
                                         %edx; длина строки */
    int     $0x80                       /* вызвать прерывание 0x80 */
    movl    $1, %eax                    /* номер системного вызова exit - 1 */
    movl    $0, %ebx                    /* передать 0 как значение параметра */
    int     $0x80                       /* вызвать exit(0) */
.size      main, . - main               /* размер функции main */
```



Программирование на ассемблере для x86

- В роли операнда ассемблерной команды могут выступать:
 - Конкретное значение, известное на этапе компиляции, — например, числовая константа или символ
 - Записываются при помощи знака \$, например: \$0xf1, \$10, \$hello_str
 - Эти операнды называются *непосредственными*
 - Регистр (перед именем регистра ставится знак %, например: %eax, %bx, %cl)
 - Указатель на ячейку в памяти
 - Неявный операнд

Программирование на ассемблере для x86

Формат ассемблерной команды:

Операция Источник, Назначение

Пример:

```
movl    $4, %eax
```

- Суффикс *l* после *mov* указывает на то, что команда работает с операндами длиной в 4 байта (*long*)
- Все суффиксы:
 - *b* (*byte*) — 1 байт
 - *w* (*word*) — 2 байта
 - *l* (*long*) — 4 байта
 - *q* (*quadword*) — 8 байт
- **Студентам:** как записать значение 41 в регистр *%al*?

Программирование на ассемблере для x86

смещение (база, индекс, множитель)

- Вычисленный адрес = база + индекс × множитель + смещение
- Множитель может принимать значения 1, 2, 4 или 8
- Например:
 - (%есх) адрес операнда находится в регистре %есх;
 - 4(%есх) адрес операнда равен %есх + 4;
 - 4(%есх) адрес операнда равен %есх – 4;
 - kuki*(, %есх, 4) адрес операнда равен *kuki* + %есх × 4, где *kuki* — некоторый адрес



Программирование на ассемблере для x86

- Директивы:

- *.byte* — размещает каждое выражение как 1 байт;
- *.short* — 2 байта;
- *.long* — 4 байта;
- *.quad* — 8 байт.

- Примеры:

```
.byte    0x10, 0xf5, 0x42, 0x55
```

```
.long    0xaabbaabb
```

```
.short   -123, 456
```



Программирование на ассемблере для x86

- Существуют директивы для размещения в памяти строковых литералов:
 - `.ascii "STR"` размещает строку STR, нулевых байтов не добавляет
 - `.string "STR"` размещает строку STR, после которой следует нулевой байт (как в языке C)
- У директивы `.string` есть синоним `.asciz` (z указывает на добавление нулевого байта)
- Строка-аргумент этих директив может содержать стандартные *escape*-последовательности языка C, например, `\n`, `\r`, `\t`, `\\`, `\"` и т.д.



Программирование на ассемблере для x86

- Данные нужно помещать в секцию данных директивой *.data*:

```
.data
```

```
    .string "Hello, goodbye and farewell\n"
```

```
    ...
```

- Если некоторые данные не предполагается изменять в ходе выполнения программы, их можно поместить в специальную секцию данных только для чтения директивой *.section .rodata*:

```
.section .rodata
```

```
    .string "program version 0.419"
```


Программирование на ассемблере для x86

- Для соблюдения выравнивания в распоряжении программиста есть директива *.p2align*

.p2align степень_двойки, заполнитель, максимум

- Второй и третий аргументы – не обязательны
- Примеры:

```
.data
```

```
    .string "Hello, goodbye and farewell\n"
```

```
/* мы вряд ли захотим считать, сколько символов
   занимает эта строка, и является ли следующий адрес
   выровненным */
```

```
    .p2align 2                /* выравниваем по
   границе 4 байта           для следующего .long */
    .long 123456
```

Программирование на ассемблере для x86

- Мы не присвоили имён нашим данным
- Как же к ним обращаться?
- Ответ: нужно поставить метку
- **Метка** — это константа, значение которой — адрес

```
hello_str:
```

```
    .string "Hello, goodbye and farewell!\n"
```

- А если нам нужна константа с каким-то другим значением?
- Тогда мы приходим к более общему понятию «символа»

Программирование на ассемблере для x86

- Просмотреть символы в объектном модуле можно, используя утилиту *nm*
- Например:

```
$ nm hello.o
```

```
00000000 d hello_str
```

```
0000000e a hello_str_length
```

```
00000000 T main
```

```
$
```

Программирование на ассемблере для x86

- Для создания нового символа используется директива `.set`
- Синтаксис:

`.set` СИМВОЛ, выражение

- Определим символ `kookoo = 42`:

```
.set kookoo, 42
```

- Ещё пример из `hello.s`:

```
hello_str:
```

```
    .string "Hello, goodbye and farewell!\n"
        /* наша строка */
```

```
    .set    hello_str_length, . - hello_str - 1
    /* длина строки */
```

Программирование на ассемблере для x86

- Для неинициализированных данных используются специальные директивы:
`.space` количество_байт
`.space` количество_байт, заполнитель
- Директива `.space` резервирует *количество_байт* байт.
- Можно использовать для размещения инициализированных данных, для этого существует параметр `заполнитель` — этим значением будет инициализирована память, например:

```
.bss
long_var_1:                /* по размеру как .long                */
    .space 4

buffer:                    /* какой-то буфер в 1024 байта                */
    .space 1024

struct:                    /* какая-то структура размером 20 байт */
    .space 20
```

Программирование на ассемблере для x86

```
.data
some_var:
    .long 0x00000072

other_var:
    .long 0x00000001, 0x00000002, 0x00000003

.text
.globl main
main:
    movl    $0x48, %eax        /* поместить число 0x00000048 в %eax */

    movl    $some_var, %eax    /* поместить в %eax значение метки
                                some_var, то есть адрес числа в
                                памяти; например, у нас
                                содержимое %eax равно 0x08049589 */

    movl    some_var, %eax      /* обратиться к содержимому переменной;
                                в %eax теперь 0x00000072 */

    movl    other_var + 4, %eax /* other_var указывает на 0x00000001
                                размер одного значения типа long — 4
                                байта; значит, other_var + 4
                                указывает на 0x00000002;
                                в %eax теперь 0x00000002 */
```

Программирование на ассемблере для x86

```
movl    $1, %ecx          /* поместить число 1 в %ecx          */

movl    other_var(,%ecx,4), %eax /* поместить в %eax первый
                                (нумерация с нуля) элемент массива
                                other_var, пользуясь %ecx как
                                индексным регистром          */

movl    $other_var, %ebx   /* поместить в %ebx адрес массива
                                other_var          */

movl    4(%ebx), %eax      /* обратиться по адресу %ebx + 4;
                                в %eax снова 0x00000002          */

movl    $other_var + 4, %eax /* поместить в %eax адрес, по
                                которому расположен 0x00000002
                                (адрес массива плюс 4 байта --
                                пропустить нулевой элемент)    */

movl    $0x15, (%eax)     /* записать по адресу "то, что записано
                                в %eax" число 0x00000015          */
```

Программирование на ассемблере для x86

inc	операнд
dec	операнд
neg	операнд
add	источник, приёмник
sub	источник, приёмник
mul	множитель_1
imul	множитель_1
div	делитель
idiv	делитель

Команда	Второй сомножитель	Результат
mulb	%al	16 бит: %ax
mulw	%ax	32 бита: младшая часть в %ax, старшая в %dx
mull	%eax	64 бита: младшая часть в %eax, старшая в %edx

Программирование на ассемблере для x86

- Примеры:

```
.text
```

```
movl    $72, %eax
```

```
incl    %eax
```

```
/* в %eax число 73 */
```

```
decl    %eax
```

```
/* в %eax число 72 */
```

```
movl    $48, %eax
```

```
addl    $16, %eax
```

```
/* в %eax число 64 */
```

```
movb    $5, %al
```

```
movb    $5, %bl
```

```
mulb    %bl
```

```
/* в регистре %ax
```

```
произведение %al × %bl = 25 */
```

Программирование на ассемблере для x86

```
movb  $0,    %ah          /* %ah = 0          */
movb  $252,  %al          /* %al = 252        */
addb  $8,    %al          /* %al = %al + 8
                          происходит переполнение,
                          устанавливается флаг cf;
                          в %al число 4          */
jnc    no_carry          /* если переполнения не было, перейти
                          на метку          */
movb  $1,    %ah          /* %ah = 1          */
no_carry:
/* %ax = 260 = 0x0104 */
```

Программирование на ассемблере для x86

- Сравнение:

cmp операнд_2, операнд_1

- Переход:

jmp метка

- Варианты:

Мнемоника	Английское слово	Смысл	Тип
je	equal	равенство	любые
jne	not	инверсия условия	любые
jg	greater	больше	со знаком
jl	less	меньше	со знаком
ja	above	больше	без знака
jb	below	меньше	без знака

jmp – безусловный переход

Программирование на ассемблере для x86

`.text`

`/* Тут пропущен код, который получает некоторое значение в %eax.`

`Пусть нас интересует случай, когда %eax = 15 */`

`cmpl $15, %eax /* сравнение */`

`jne not_equal /* если операнды не равны, перейти на метку not_equal */`

`/* сюда управление перейдёт только в случае, когда переход не сработал, а значит, %eax = 15 */`

`not_equal:`

`/* а сюда управление перейдёт в любом случае */`

Память

- Число 0x04030201 можно записать в виде байтовой последовательности:
 - начиная со старшего байта: 0x04 0x03 0x02 0x01 — *big-endian*
 - начиная с младшего байта: 0x01 0x02 0x03 0x04 — *little-endian*
- Адрес всего слова в памяти – адрес первого байта последовательности



Методы адресации

- Пространство памяти предназначено для хранения кодов команд и данных, для доступа к которым имеется богатый выбор методов адресации
- Операнды могут находиться во внутренних регистрах процессора
- Они могут располагаться в системной памяти
- Они могут находиться в устройствах ввода/вывода
- Определение местоположения операндов производится кодом команды

Методы адресации

- Прямая или абсолютная адресация
- Физический адрес операнда содержится в адресной части команды, формально:
- $\text{Операнд}_i = (A_i)$
- A_i – код, содержащийся в i -м адресном поле команды.

```
.data  
num:
```

```
    .long    0x12345678
```

```
.text  
main:
```

```
    movl     (num), %eax    /* Записать в регистр %eax операнд,  
                           который содержится в оперативной  
                           памяти по адресу метки num          */
```

```
    addl     (num), %eax    /* Сложить с регистром %eax операнд,  
                           который содержится в оперативной  
                           памяти по адресу метки num и записать  
                           результат в регистр %eax          */
```

```
    ret
```

Методы адресации

- Непосредственная адресация
- В команде содержится не адрес операнда, а непосредственно сам операнд
- Операнд_i = A_i

```
.text  
main:
```

```
movl    $0x12345, %eax
```

```
/* загрузить константу 0x12345 в  
   регистр %eax.          */
```


Методы адресации

- Косвенная (базовая) адресация
- Адресная часть команды указывает адрес ячейки памяти или регистр, в котором содержится адрес операнда
- $\text{Операнд}_i = ((A_i))$

```
.data  
num:
```

```
.long    0x1234
```

```
.text  
main:
```

```
movl    $num, %ebx    /* записать адрес метки в регистр  
                        адреса %ebx */
```

```
movl    (%ebx), %eax   /* записать в регистр %eax операнд из  
                        оперативной памяти, адрес которого  
                        находится в регистре адреса %ebx */
```

Методы адресации

- Регистровая адресация
- Предполагается, что операнд находится во внутреннем регистре процессора

```
.text  
main:
```

```
movl    $0x12345, %eax    /* записать в регистр константу 0x12345  
                           */  
movl    %eax, %ecx        /* записать в регистр %ecx операнд,  
                           который находится в регистре %eax */
```

Методы адресации

- Относительная адресация
- Используется тогда, когда память логически разбивается на блоки — **сегменты**

Операнд_i = (база_i + смещение_i)

- Пример 1
 - адресное поле команды состоит из двух частей, в одной указывается номер регистра, хранящего базовое значение адреса, а в другой задается смещение, определяющее положение ячейки относительно начала сегмента
 - Это собственно относительная адресация

Методы адресации

- Относительная адресация
- Используется тогда, когда память логически разбивается на блоки — **сегменты**
- $\text{Операнд}_i = (\text{база}_i + \text{смещение}_i)$
- Пример 2
 - Первая часть адресного поля команды также определяет номер базового регистра, а вторая содержит номер регистра, в котором находится смещение
 - Это базово-индексная адресация

Команды для адресов и стека

`lea` источник, назначение

`.data`

`some_var:`

`.long 0x00000072`

`.text`

`leal 0x32, %eax` /* аналогично `movl $0x32, %eax` */

`leal some_var, %eax` /* аналогично `movl $some_var, %eax` */

`leal $0x32, %eax` /* вызовет ошибку при компиляции,
так как `$0x32` - непосредственное
значение */

`leal $some_var, %eax` /* аналогично, ошибка компиляции:
`$some_var` - это непосредственное
значение, адрес */

`leal 4(%esp), %eax` /* поместить в `%eax` адрес предыдущего
элемента в стеке;
фактически, `%eax = %esp + 4` */

Команды для адресов и стека

Вычисленный адрес = база + индекс × множитель + смещение

```
movl    $10, %eax
movl    $7, %ebx
```

```
leal    5(%eax)      , %ecx    /* %ecx = %eax + 5 = 15          */
leal    -3(%eax)     , %ecx    /* %ecx = %eax - 3 = 7          */
leal    (%eax,%ebx)   , %ecx    /* %ecx = %eax + %ebx × 1 = 17  */
leal    (%eax,%ebx,2) , %ecx    /* %ecx = %eax + %ebx × 2 = 24  */
leal    1(%eax,%ebx,2), %ecx    /* %ecx = %eax + %ebx × 2 + 1 = 25 */
leal    (,%eax,8)     , %ecx    /* %ecx = %eax × 8 = 80         */
leal    (%eax,%eax,2) , %ecx    /* %ecx = %eax + %eax × 2 = %eax × 3 = 30 */
leal    (%eax,%eax,4) , %ecx    /* %ecx = %eax + %eax × 4 = %eax × 5 = 50 */
leal    (%eax,%eax,8) , %ecx    /* %ecx = %eax + %eax × 8 = %eax × 9 = 90 */
```

Команды для адресов и стека

- Две специальные команды: *push* (поместить в стек) и *pop* (извлечь из стека)
- Синтаксис:
push источник
pop назначение
- **Студентам:** как отреагирует компилятор, если задать команду *pushb 0x34*?

Команды для адресов и стека

.text

```
    pushl $0x10          /* поместить в стек число 0x10      */
    pushl $0x20          /* поместить в стек число 0x20      */
    popl  %eax           /* извлечь 0x20 из стека и записать в
                           %eax                                             */
    popl  %ebx           /* извлечь 0x10 из стека и записать в
                           %ebx                                             */

    pushl %eax           /* странный способ сделать         */
    popl  %ebx           /* movl %eax, %ebx                  */

    movl  $0x00000010, %eax
    pushl %eax           /* поместить в стек содержимое %eax */
    popw  %ax            /* извлечь 2 байта из стека и
                           записать в %ax                                  */
    popw  %bx            /* и ещё 2 байта и записать в %bx    */
                           /* в %ax находится 0x0010, в %bx     */
                           /* находится 0x0000; такой код сложен */
                           /* для понимания, его следует избегать */

    pushl %eax           /* поместить %eax в стек; %esp
                           уменьшится на 4                                */
    addl  $4, %esp        /* увеличить %esp на 4; таким образом,
                           стек будет приведён в исходное
                           состояние                                         */
```


Подпрограммы: общие принципы

- **Вызов подпрограммы** - это передача управления по адресу начала подпрограммы с одновременным запоминанием в стеке адреса возврата
- Адрес возврата - адрес команды, непосредственно следующей за командой вызова)
- Процессоры семейства x86_32 предусматривают для этой цели команду *call*
- Она похожа на *jmp*
- Возврат из подпрограммы производится командой *ret*

Подпрограммы: общие принципы

```
.data
printf_format: /* форматная строка для вывода заполненного байтового массива */
               .string "%s\n"

.bss
array: .space 80 /* Байтовый массив для заполнения */

.text
.globl main
main:
    mov $array, %edi
    movl $80, %ecx
    movb $0x41, %al
    call fill_memory

/*
 * следующий код выводит число в %eax на экран и завершает программу
 */
    pushl $array
    pushl $printf_format
    call printf
    addl $8, %esp

    movl $0, %eax
    ret
```

Подпрограммы: общие принципы

```
/* Подпрограмма fill memory
 * (edi = адрес, ecx = размер, al = байт-
 *   заполнитель)
 */
fill_memory:
    jecxz fm_q
fm_lp:
    movb %al, (%edi)
    incl %edi
    loop fm_lp
fm_q:
    ret
```

Организация стековых фреймов

- Обычно параметры в подпрограммы передаются через стек
- Там же размещают локальные переменные
- Параметры в стеке размещает вызывающая программа
- Затем при вызове подпрограммы в стек заносится адрес возврата, а после этого сама вызванная подпрограмма резервирует в стеке место под локальные переменные
- Все это в совокупности образует **стековый фрейм**

Организация стековых фреймов

- Если в стек занести три четырехбайтных параметра, а потом вызвать подпрограмму, то адрес возврата будет лежать в памяти по адресу (`%esp`), а параметры окажутся доступными по адресам `4(%esp)`, `8(%esp)` и `12(%esp)`
- Если разместить в стеке локальные 4-байтные переменные, то они окажутся доступными по адресам:
`-4(%esp)`, `-8(%esp)` и т.д.

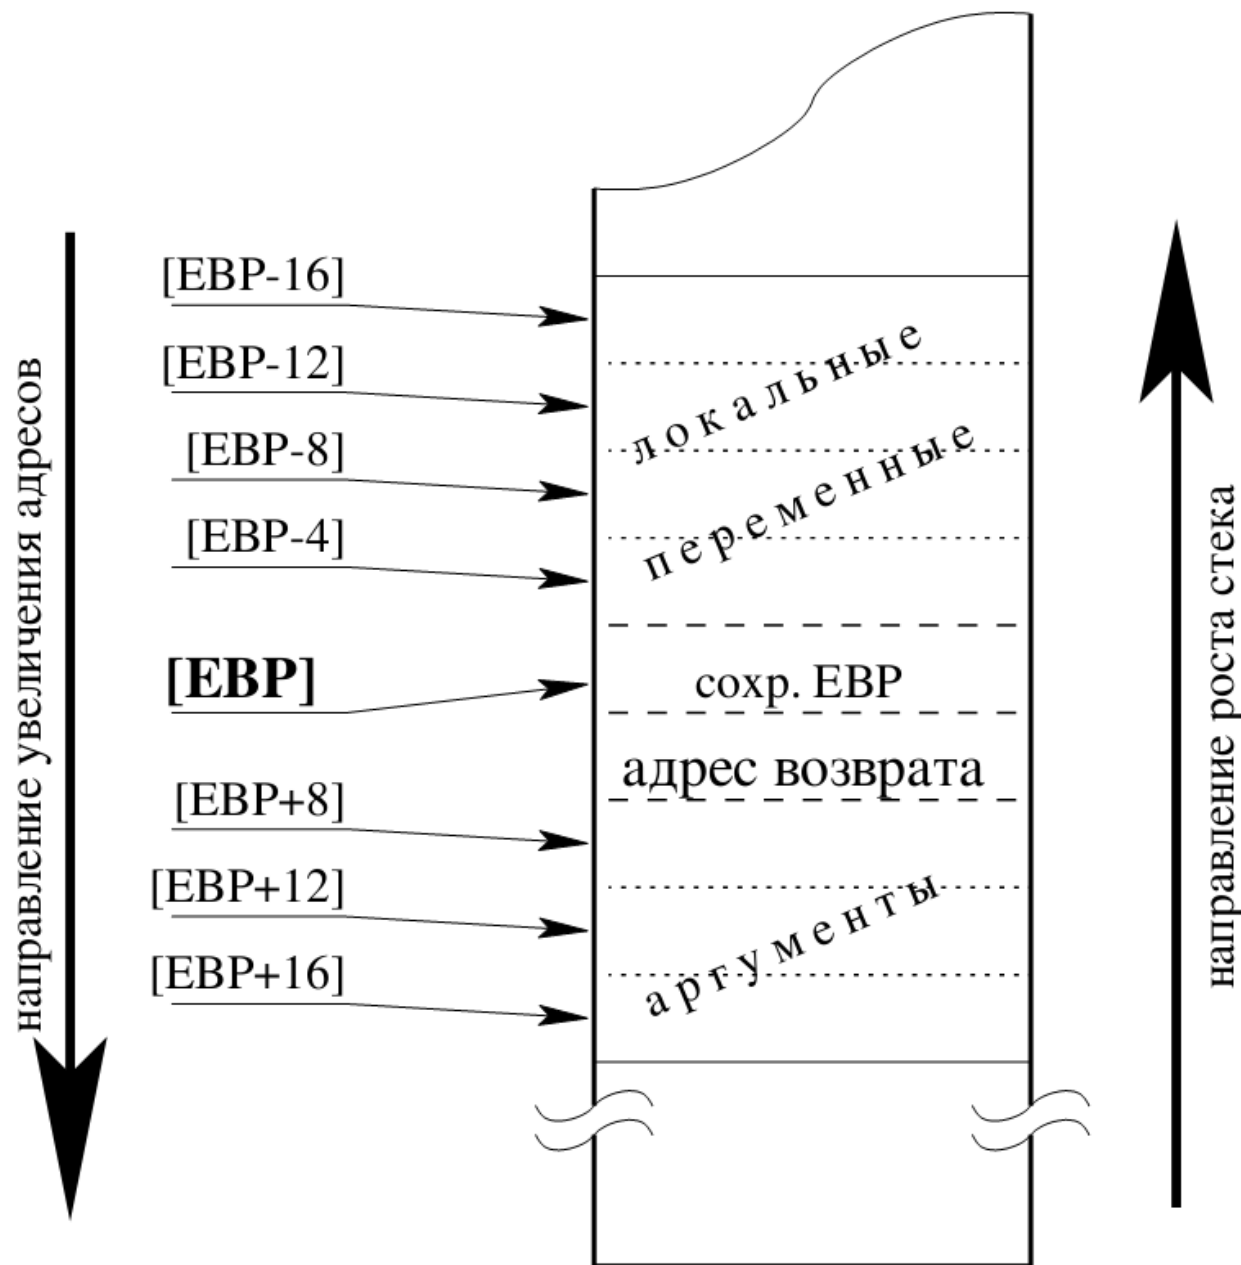
Организация стековых фреймов

- Первым своим действием подпрограмма обычно сохраняет значение регистра `%esp` в каком-то другом регистре, обычно `%ebp`
- Он используется для доступа к параметрам и локальным переменным
- В то же время `%esp` продолжает играть роль указателя стека, изменяясь по мере необходимости
- Перед возвратом из подпрограммы его обычно восстанавливают в исходном значении за счет пересылки в него значения из `%ebp`, чтобы оно снова указывал на адрес возврата

Организация стековых фреймов

- Каждая подпрограмма должна сама сохранять старое значение `%ebp` и восстановить его перед возвратом управления
- Для сохранения значения `%ebp` тоже используется стек (*push %ebp* сразу после получения управления)
- Старое значение `%ebp` помещается в стек непосредственно после адреса возврата из подпрограммы
- Следующая команда – *movl %esp, %ebp*

Организация стековых фреймов



Организация стековых фреймов

```
/* пролог */  
pushl %ebp  
movl %esp, %ebp  
subl $16, %esp
```

```
/* эпилог */  
movl %ebp, %esp  
popl %ebp  
ret
```

See also

- Магда, Ю.С. Ассемблер для процессоров Intel Pentium/ Ю.С. Магда. – СПб.: Питер, 2006. – 416 с.
- Робачевский, А. Операционная система Unix, 2 изд./ А.Робачевский, С.Немнюгин, О.Стесик. – СПб.: БХВ-Петербург, 2010. – 656 с.
- Столяров, А.В. Программирование на языке ассемблера NASM для ОС UNIX: учеб.пособие. – М.: Макс, 2011. – 188 с. – Доступ: http://www.stolyarov.info/books/asm_unix
- flat assembler - <http://www.flatassembler.net/>
- The Netwide Assembler: NASM - <http://nasm.us/>
- Intel® 64 and IA-32 Architectures Optimization Reference Manual, 3.5.1.3 Using LEA.
- Intel® 64 and IA-32 Architectures Software Developer's Manual, 4.1 Instructions (N-Z), PUSH
- Ассемблер в Linux для программистов С – http://ru.wikibooks.org/wiki/Ассемблер_в_Linux_для_програ